



دانشکده مهندسی و علوم کامپیوتر

چهر خطی - دکتر ملک

بهار ۱۴۰۴

پروژه پایانی درس

گردآورندگان: سینا عربی - پوریا یزدانی -

بردیا کریمی نیا - آراس ولیزاده

در دنیای امروز، ما هر روز با انبوهی از انتخاب‌ها مواجه هستیم؛ از انتخاب فیلم و موسیقی گرفته تا خرید آنلاین و مطالعات علمی. در چنین شرایطی، تصمیم‌گیری بدون کمک ابزارهای هوشمند ممکن است خسته‌کننده، زمان‌بر و گاهی ناکارآمد باشد. سیستم‌های پیشنهاددهنده (Recommender Systems) به عنوان یکی از پرکاربردترین راه‌حل‌های داده‌محور، تلاش می‌کنند بر اساس علایق گذشته‌ی کاربران یا شباهت آن‌ها با دیگر کاربران، پیشنهادهای شخصی‌سازی‌شده‌ای ارائه دهند.



**RECOMMENDER
SYSTEM
SBU**

در این پروژه، ما یک سیستم پیشنهاددهنده‌ی ساده و مفهومی با نام **CineMatch** طراحی کرده‌ایم که تمرکز آن بر تحلیل امتیاز دهی کاربران به فیلم‌هاست. هدف اصلی این سیستم، پیش‌بینی فیلم‌هایی است که احتمالاً برای هر کاربر جذاب خواهد بود. اما برخلاف بسیاری از پروژه‌های مشابه که از الگوریتم‌های یادگیری ماشین پیشرفته استفاده می‌کنند، در CineMatch تلاش شده تا از ابزارها و مفاهیم پایه‌ای جبر خطی استفاده شود تا شما بتوانید کاربرد مستقیم ریاضیات را در حل مسائل واقعی لمس کنید.

در هسته‌ی این سیستم، از روش‌هایی مانند تجزیه مقدار منفرد (SVD)، تجزیه به مؤلفه‌های اصلی (PCA)، تقریب ماتریس‌های با رتبه پایین و ضرب داخلی بردارها استفاده شده است. این روش‌ها به ما کمک می‌کنند تا الگوهای پنهان بین کاربران و فیلم‌ها را شناسایی کنیم؛ برای مثال اینکه یک کاربر به ژانر خاصی علاقه دارد، حتی اگر خودش مستقیماً آن را بیان نکرده باشد. فضای حاصل از این تجزیه‌ها، یک فضای دو بعدی یا سه‌بعدی است که در آن می‌توان کاربران و فیلم‌ها را به شکل بردارهایی در نظر گرفت و از طریق هندسه و شباهت زاویه‌ای بین آن‌ها، کیفیت ارتباط بین سلیقه‌ی کاربران و ویژگی‌های فیلم‌ها را تخمین زد.

در این مسئله با دو ماهیت اصلی فیلم و کاربر مواجه هستیم و تلاش می‌کنیم به کمک داده‌هایی که از ارتباط بین کاربران با فیلم‌های مختلف در اختیار داریم، فیلم‌های دیگری به هر کاربر با سلیقه خاص خودش پیشنهاد کنیم. برای این منظور از امتیازهایی که توسط کاربران برای فیلم‌ها ثبت شده استفاده می‌کنیم. مجموعه X را شامل همه کاربران و مجموعه S شامل تمام فیلم‌ها فرض کنید. ماتریس Rating زیر که ستون‌های آن شامل کاربران و سطرهای آن شامل فیلم‌ها می‌باشد را در نظر بگیرید:

		users											
		1	2	3	4	5	6	7	8	9	10	11	12
movies	1	1		3			5			5		4	
	2			5	4			4			2	1	3
	3	2	4		1	2		3		4	3	5	
	4		2	4		5			4			2	
	5			4	3	4	2					2	5
	6	1		3		3			2			4	


هدف اصلی سیستم توصیه گر پیش بینی امتیاز یک کاربر خاص به فیلم هایی است که تا به حال برای آن امتیازی ثبت نکرده باشد، تا در نهایت فیلم هایی که امتیاز بالایی برای آنها پیش بینی می شود را به کاربر پیشنهاد کنیم. به طور کلی برای این مسئله سه روش زیر وجود دارد:

- Content-based
- Collaborative
- Latent factor based


****** توجه کنید که هدف اصلی پروژه استفاده از مفاهیم جبر خطی برای حل کردن صورت مسئله می باشد، بر همین اساس از شما انتظار می رود که حتماً یک بار روش سوم و آموخته های مرتبط با تجزیه SVD این مسئله را حل کنید؛ اما برای کسب نمرات امتیازی پروژه و کسب امتیاز بهتر در بخش ارزیابی می توانید از هر روش دیگری استفاده کنید. ******

در روش سوم، به جای اینکه به طور مستقیم به شباهت بین کاربران یا شباهت بین فیلم ها توجه کنیم، تلاش می کنیم الگوهای پنهانی را کشف کنیم که در تعامل بین کاربران و فیلم ها نقش دارند. به عبارتی، فرض می کنیم که ارتباط هر کاربر و هر فیلم را می توان با چند ویژگی پنهان توصیف کرد، بدون اینکه نیاز باشد این ویژگی ها را صراحتاً مشخص کنیم. برای این منظور از روش SVD استفاده می کنیم. همانطور که می دانیم، هر ماتریس A را بصورت زیر تجزیه کرد:

$$A = U \Sigma V^T$$



حالا به کمک این روش ماتریس امتیازدهی را به صورت زیر تجزیه می‌کنیم:



متناظر با فاکتورهای تجزیه SVD داریم:

$$A = R, Q = U, P^T = \Sigma V^T$$

پرسش: درباره تعبیر شهودی‌ای که از فاکتورهای Q و P^T می‌توان استخراج کرد توضیح دهید.

چالشی که برای تجزیه ماتریس R با آن مواجه هستیم، خالی بودن مقدار برخی درایه‌های این ماتریس می‌باشد، که پیدا کردن فاکتورهای تجزیه را مشکل‌ساز می‌کند.

پرسش: درباره راه‌حل‌های موجود برای این چالش تحقیق کنید و توضیح دهید چرا راه‌حل شما برای یادگیری الگوهای موجود برای امتیازهای ثبت شده در ماتریس R مناسب است.

بعد از پیدا کردن فاکتورهای تجزیه ذکر شده، به کمک عبارت زیر می‌توانید امتیاز کاربر x به یک فیلم i را پیش‌بینی کنید:

$$\hat{r}_{xi} = q_i \cdot p_x^T$$

در نهایت برای ارزیابی پیش‌بینی‌ها باید فاصله بین مقادیر پیش‌بینی شده با مقادیر واقعی امتیازها را مقایسه کنیم، برای این کار می‌توانیم از متد RMSE به صورت زیر استفاده کنیم:

$$\frac{1}{|R|} \sqrt{\sum_{(i,x) \in R} (\hat{r}_{xi} - r_{xi})^2}$$

تحلیل نتایج

انرژی و واریانس توضیح داده‌شده

مقادیر تکین را از SVD محاسبه کنید و سهم هر مؤلفه را در مجموع «انرژی» داده‌ها بسنجید. نمودار انرژی هر مؤلفه و نمودار واریانس تجمعی را رسم کنید تا ببینید با افزایش تعداد مؤلفه‌ها چقدر از واریانس داده‌ها پوشش داده می‌شود. با در نظر گرفتن چند مؤلفه اول بهترین rmse مدل شما بدست می‌آید؟ نمودارهایی رسم کنید که این تغییرات در آن‌ها مشخص باشد. مثلاً می‌توانید نموداری بر حسب rmse در برابر k رسم کنید.

تفسیر عامل‌های پنهان

برای سه مؤلفه‌ی اول در فضای عامل‌های پنهان، فیلم‌ها (و کاربران) را در دو انتهای مثبت و منفی هر بُعد شناسایی کنید. برای این فیلم‌ها اطلاعات ساده‌ای مانند سال انتشار، میانگین امتیاز را گزارش دهید. سپس بررسی کنید که آیا می‌توان برای هر یک از این عامل‌های پنهان معنایی قابل تفسیر در نظر گرفت یا خیر. برای مثال، ممکن است فیلم‌هایی که در بُعد اول مقدار زیادی دارند، همگی به یک ویژگی خاص تعلق داشته باشند. بر این اساس، تلاش کنید یک فرض کوتاه و مستدل درباره‌ی معنای احتمالی هر عامل پنهان ارائه دهید. در ادامه، روابط میان کاربران و فیلم‌هایی که به آن‌ها امتیاز بالاتری داده‌اند را بررسی کنید. آیا کاربران را می‌توان در همان فضای عامل‌های پنهان، مشابه با فیلم‌ها، نمایش داد؟ اگر چنین نمایشی ممکن باشد، چه الگوهایی میان نزدیکی کاربران و فیلم‌های مورد علاقه‌شان در این فضا قابل مشاهده است؟ در نهایت، توصیه می‌شود عامل‌های پنهان را به صورت جداگانه و همچنین به صورت دو به دو (Pairwise) با یکدیگر مقایسه و تحلیل کنید تا درک بهتری از ساختار فضای پنهان به دست آید.

خوشه‌بندی

می‌دانیم ماتریس Q نمایش‌دهنده فیلم‌ها در فضای پنهان است. روی این داده خوشه‌بندی انجام دهید و فیلم‌ها را دسته‌بندی کنید. آیا فیلم‌هایی که در یک خوشه می‌افتند را می‌توان به هم ارتباط داد؟ با اعمال روش‌های کاهش ابعاد، خوشه‌بندی را در فضای ۲ یا ۳ بعدی نشان دهید. در بخش خوشه بندی، استفاده از کتابخانه‌های آماده مشکلی ندارد.

هرگونه خلاقیت در بررسی نتایج، پیش‌پردازش، پس‌پردازش و کشف الگو یا ارتباط بین کاربران، فیلم‌ها و کاربران و فیلم‌ها در این پروژه نمره امتیازی دارد.

موارد ارزیابی:

- برای ارزیابی کارایی سیستم توصیه گر، مقدار RMSE روی داده تستی که در اختیار شما قرار داده شده است باید از مقدار ۰.۹۴ (نود و چهار صدم) کمتر باشد.
- برای پیاده سازی سیستم خود باید از قواعد گفته شده در متن پروژه نظیر SVD حتما در پیاده‌سازی استفاده شود.
- برای تجزیه SVD و PCA مجاز به استفاده از کتابخانه‌ها نمی‌باشید.
- تنها در صورتی مجاز به پیاده‌سازی بخش امتیازی (استفاده از مدل‌های یادگیری ماشین و ..) هستید که پیاده‌سازی فاز اجباری را با مقدار RMSE مجاز، انجام داده باشید، در غیراینصورت نمره امتیازی تعلق نخواهد گرفت.

نکات پروژه:

۱. سوالات و ابهامات خود را می‌توانید با دستیاران آموزشی در دیسکاشن درس مطرح کنید.
۲. فایل نهایی خود را در کوئرا درس آپلود کنید. دقت کنید پروژه به صورت انفرادی می‌باشد.
۳. درصد شباهت بالا در فایل های آپلودی **تقلب** تلقی می‌شود.
۴. سه نفر اول به ترتیب، ۳۰، ۲۰ و ۱۰ نمره امتیازی دریافت خواهند کرد.
۵. استفاده از روش‌های جبرخطی برای بهبود RMSE ۲۵ نمره امتیازی و استفاده از روش‌های یادگیری ماشین و .. ۱۰ نمره امتیازی خواهد داشت. دقت کنید به روش پیاده سازی باید تسلط کامل داشته باشید و صرف استفاده از یک مدل یادگیری ماشین کافی نمی‌باشد.
۶. فرمت نام گذاری فایل پاسخگویی به شکل زیر باشد:

LA-Project-StudentNumber-FullName

موفق باشید:)